

Çevrimdışı İmza Doğrulamada Transfer Öğrenme Başarımının Farklı Yazı Sistemleri ve CNN Omurgaları Üzerinden Değerlendirilmesi

Evaluation of Transfer Learning Performance in Offline Signature Verification Across Writing Systems and CNN Backbones

Esma Fazilet Karagülle

Özet

Çevrimdışı imza doğrulama, taranmış veya görüntülenmiş imza örnekleri üzerinden gerçek ve sahte imzaların ayırt edilmesini amaçlayan zorlu bir biyometrik doğrulama problemidir. Bu zorluk, aynı kişiye ait gerçek imzaların doğal değişkenlik göstermesi ve yetenekli sahtecilerin hedef imzanın genel biçimsel özelliklerini taklit edebilmesinden kaynaklanmaktadır. Derin öğrenme ve transfer öğrenme tabanlı yaklaşımlar bu alanda güçlü sonuçlar üretmekle birlikte bu sonuçların farklı veri setleri, yazı sistemleri ve değerlendirme protokollerinde aynı biçimde ortaya çıkıp çıkmadığı ayrıca sınanmalıdır. Bu çalışmada transfer öğrenme tabanlı modeller; yazı sistemi, değerlendirme protokolü, CNN omurgası ve ince ayar stratejisi birlikte dikkate alınarak incelenmiştir. Latin karakterli CEDAR, Bengali ve Devanagari karakterli BHSig260 ve Perso-Arabik karakterli UTSig veri setleri kullanılmıştır. ImageNet üzerinde önceden eğitilmiş ResNet50, VGG19, DenseNet121 ve EfficientNet-B0 omurgaları donmuş omurga yaklaşımıyla karşılaştırılmış ayrıca VGG19 için son evrişim bloğunun çözülmesine dayalı bir ince ayar ablasyonu yapılmıştır. Toplam 30 deney, yazar-bağımlı ve yazar-bağımsız protokoller altında yürütülmüş olup modeller doğruluk, kesinlik, duyarlılık, F1-skoru, ROC-AUC, FAR, FRR, AER ve EER metrikleriyle analiz edilmiştir. Bulgular, VGG19'un altı temel senaryonun dördünde en yüksek doğruluk değerine ulaştığını ancak yazar-bağımsız UTSig senaryosunda belirgin biçimde gerilediğini göstermektedir. Son blok ince ayarı çoğu senaryoda EER ve ROC-AUC değerlerini iyileştirmiş ancak CEDAR-WI senaryosunda doğruluk ve ROC-AUC bakımından performans kaybına yol açmıştır. Sonuçlar, çevrimdışı imza doğrulamada farklı yazı sistemleri, WD/WI protokol ayrımı ve biyometrik hata ölçütlerinin birlikte değerlendirilmesi gerektiğini göstermektedir.

Anahtar Kelimeler: çevrimdışı imza doğrulama, transfer öğrenme, yazar-bağımsız değerlendirme, biyometrik metrikler, CNN omurgaları.

Abstract

Offline signature verification is a challenging biometric verification problem that aims to distinguish genuine and forged signatures from scanned or image-captured samples. This difficulty arises from the natural intra-writer variability of genuine signatures and from the ability of skilled forgers to imitate the general structural characteristics of the target signature. Although deep learning and transfer learning-based approaches have produced strong results in this field, it remains necessary to examine whether similar results are obtained across different datasets, writing systems, and evaluation protocols. In this study, transfer learning-based models were investigated by jointly considering the writing system, evaluation protocol, CNN backbone, and fine-tuning strategy. The Latin-script CEDAR, Bengali and Devanagari-script BHSig260, and Perso-Arabic-script UTSig datasets were used. ResNet50, VGG19, DenseNet121, and EfficientNet-B0 backbones pre-trained on ImageNet were compared under a frozen-backbone setting; additionally, a fine-tuning ablation was performed for VGG19 by unfreezing its final convolutional block. A total of 30 experiments were conducted under writer-dependent and writer-independent protocols, and the models were analyzed using accuracy, precision, recall, F1-score, ROC-AUC, FAR, FRR, AER, and EER. The findings show that VGG19 achieved the highest accuracy in four of the six main scenarios, but declined markedly in the writer-independent UTSig scenario. Fine-tuning the final block improved EER and ROC-AUC in most scenarios, whereas it caused a performance decrease in CEDAR-WI in terms of accuracy and ROC-AUC. Overall, the results indicate that offline signature verification should be assessed by jointly considering different writing systems, the WD/WI protocol distinction, and biometric error measures.

Keywords: offline signature verification, transfer learning, writer-independent evaluation, biometric metrics, CNN backbones.

1. Giriş

İmza, bireyin kimliğini temsil eden hukuki, finansal, bankacılık ve idari işlemlerde yaygın biçimde kullanılan davranışsal bir biyometrik özelliktir. Parmak izi veya iris gibi fizyolojik biyometriklerden farklı olarak imza, her üretimde küçük biçimsel değişiklikler gösterebilir. Bu kişi-içi değişkenlik, gerçek imzaların birbirinden tamamen aynı olmamasına yol açarken yetenekli sahtecilerin hedef kişinin imzasını görsel olarak taklit edebilmesine de sebep olur. Bu nedenle çevrimdışı imza doğrulama yalnızca iki sınıflı bir görüntü sınıflandırma problemi değil; güvenlik, kullanıcı deneyimi ve hata maliyetleri bakımından hassas bir biyometrik karar problemidir [1]. Çevrimiçi sistemler imza üretimi sırasında kalem hızı, basınç, ivme ve yörünge gibi dinamik bilgileri kullanabilirken çevrimdışı sistemler yalnızca taranmış ya da görüntülenmiş statik imza görüntülerine dayanır. Dinamik bilginin bulunmaması özellikle gerçek imza ile yetenekli sahte imza arasındaki ince farkların modellenmesini zorlaştırır; buna karşın çevrimdışı doğrulama, özel donanım gerektirmemesi nedeniyle belge arşivleri, çek işleme, sözleşme doğrulama ve kurumsal evrak süreçleri için daha uygulanabilir bir senaryo sunar [1, 2].

Çevrimdışı imza doğrulama literatürü uzun süre doku tabanlı öznitelikler, geometrik tanımlayıcılar, kontur analizleri ve istatistiksel sınıflandırıcılar üzerine kurulmuştur. Ancak elle tasarlanmış öznitelikler veri setine, yazı stiline ve ön işleme adımlarına duyarlı olabildiğinden farklı yazarlar ve farklı yazı sistemleri arasında genellenebilirlik sorunu ortaya çıkabilmektedir [1]. Derin öğrenme yaklaşımları, öznitelikleri doğrudan imza görüntülerinden öğrenerek bu sınırlılığı azaltmayı hedeflemiştir. Hafemann ve arkadaşları, yazar-bağımsız biçimde eğitilen derin CNN temsillerinin farklı kullanıcılara ve bazı veri setleri arasında aktarılabilirliğini göstermiştir [2]. Dey ve arkadaşlarının SigNet modeli ise imza çiftlerini ortak ağırlıklı ikiz ağlardan geçirerek benzerlik ve ayrışmayı temsil uzayında öğrenmiş; böylece yazar-bağımsız doğrulama için Siamese mimarının güçlü bir çerçeve sunabileceğini ortaya koymuştur [3]. İmza veri setlerinin çoğu sınırlı sayıda gerçek ve sahte örnek içerdiğinden derin ağların sıfırdan eğitilmesi özellikle küçük veri setlerinde aşırı uyum ve kararsız genelleme riski doğurabilir [1, 2]. Bu nedenle transfer öğrenme, ImageNet gibi büyük ölçekli görsel veri kümelerinde öğrenilen temsillerin çevrimdışı imza doğrulama görevine aktarılması için yaygın bir strateji olarak kullanılmaktadır [4-7]. Bununla birlikte transfer öğrenme başarısı yalnızca kullanılan CNN omurgasının kapasitesine bağlı değildir; kaynak alan ile hedef imza verisi arasındaki benzerlik, yazı sistemi, veri seti yapısı, yazar-bağımlı/yazar-bağımsız değerlendirme protokolü ve kullanılan hata ölçütleri sonuçların yorumunu doğrudan etkileyebilir [2, 3, 5-7]. Bu nedenle çevrimdışı imza doğrulamada yüksek başarımlı iddialarının tek bir veri seti veya tek bir protokol üzerinden değil, farklı yazı sistemleri ve biyometrik hata ölçütleri birlikte dikkate alınarak değerlendirilmesi gerekir. Bu gereklilik özellikle yazı sistemi ve değerlendirme protokolü açısından önemlidir. Latin, Indic ve Perso-Arabik imzalar çizgi sürekliliği, yönelim, nokta ve diakritik kullanımı, birleşik yapı ve görsel karmaşıklık bakımından farklılaşabilir. Dolayısıyla bir yazı sisteminde elde edilen yüksek başarımlı başka bir yazı sistemine doğrudan genellenebilir olduğu varsayılmaz. Benzer biçimde, yazar-bağımlı (writer-dependent, WD) değerlendirme modelin eğitimde gördüğü yazarların örneklerinden yararlandığı koşulları temsil ederken yazar-bağımsız (writer-independent, WI) değerlendirme eğitimde hiç görülmeyen kişilere genelleme yapmayı gerektirir ve daha zorlayıcı bir senaryo sunar [2, 3, 6]. Güvenlik-kritik bir biyometrik uygulama olan imza doğrulamada doğruluk tek başına yeterli değildir; FAR, FRR, AER ve EER gibi ölçütler sahte imzaların kabul edilmesi ile gerçek kullanıcıların reddedilmesi arasındaki pratik dengeyi görünür kılar [1, 10].

Son yıllarda öz-gözetimli öğrenme, çok ölçekli metrik öğrenme, karar eşiği tasarımı, akış tabanlı değerlendirme, adversarial sağlamlık, üretici temsiller, çapraz-veri genelleme ve prototipik negatif örnek üretimi gibi yaklaşımlar çevrimdışı imza doğrulamada genelleme ve güvenilirlik sorununu daha görünür hâle getirmiştir [8-15]. Bu eğilimler, alandaki performans iddialarının yalnızca yüksek doğruluk değerleriyle değil; veri seti, yazı sistemi, protokol ve biyometrik hata ölçütleriyle birlikte değerlendirilmesi gerektiğini desteklemektedir.

Tablo 1, çevrimdışı imza doğrulama literatüründe problem tanımı, temsil öğrenimi, transfer öğrenme, öz-gözetimli öğrenme, metrik öğrenme, eşikleme stratejileri ve güncel genelleme odaklı yaklaşımları karşılaştırmalı

olarak özetlemektedir. Tablo, bu çalışmanın tek bir model önerisinden çok, transfer öğrenme başarımının farklı yazı sistemleri, WD/WI protokolleri ve CNN omurgaları altında nasıl değiştiğini inceleyen konumunu açık hâle getirmek amacıyla hazırlanmıştır.

Tablo 1. Çevrimdışı imza doğrulama literatüründe seçilmiş çalışmaların karşılaştırmalı özeti.

Çalışma	Veri seti / protokol	Yöntem	Temel bulgu / katkı	Kapsam / sınırlılık
Hafemann vd. (2015) [1]	Derleme; GPDS, CEDAR, MCYT, BHSig	Literatür derlemesi	Çevrimdışı imza doğrulamada kişi-içi değişkenlik, yetenekli sahtecilik ve protokol farklılıklarını sistematikleştirir.	Deneysel model sunmaz; 2015 sonrası derin öğrenme yaklaşımlarını kapsamaz.
Hafemann vd. (2017) [2]	GPDS, MCYT, CEDAR, PUC-PR; WI	Derin CNN temsilleri	Yazar-bağımsız CNN temsillerinin imza doğrulamada aktarılabilir özellikler öğrenebildiğini gösterir.	Sonuçlar ağırlıklı olarak GPDS üzerinde tartışılır; yazı sistemi ve omurga duyarlılığı sınırlı kalır.
Dey vd. (2017) [3]	CEDAR, GPDS300, GPDS Synthetic, BHSig-Bengali, BHSig-Hindi; WI	SigNet; Siamese CNN	İmza çiftleri üzerinden benzerlik/ayırışma öğrenerek WI doğrulama için etkili bir Siamese çerçeve sunar.	Çift üretimi hesaplama maliyetini artırır; performans veri seti özelliklerine duyarlıdır.
Mersa vd. (2019) [5]	UTSig, MCYT-75, GPDS-Synthetic	Persian handwriting transfer + residual CNN + SVM	Kaynak alan ile hedef yazı sistemi yakınlığının Perso-Arabik imzalarda transfer başarımını artırabileceğini gösterir.	Sonuçlar kaynak alan seçimi ve SVM doğrulama aşamasına bağlıdır.
Souza vd. (2020) [6]	GPDS-300, CEDAR, MCYT; WI	SigNet temsilleri + BPSO öznetelik seçimi	Derin özneteliklerin tamamının eşit katkı sağlamadığını; öznetelik seçiminin daha kompakt temsil üretebildiğini gösterir.	Odak CNN omurgası karşılaştırmasından çok öznetelik seçimi üzerindedir.
Özyurt vd. (2024) [7]	Özel veri seti; 420 kişi, 12.600 gerçek imza	MobileNetV2 + öznetelik seçimi + klasik sınıflandırıcılar	Transfer öğrenme ve öznetelik seçiminin sınıflandırma doğruluğunu artırabileceğini gösterir.	Yetenekli sahtecilik içeren standart doğrulama protokolleriyle doğrudan karşılaştırılabilirliği sınırlıdır.
Chattopadhyay vd. (2022) [8]	BHSig-Bengali, BHSig-Hindi; WI ve çapraz-yazı	Öz-gözetimli ön eğitim + dual triplet loss	Öz-gözetimli temsil öğrenme ve metrik öğrenmenin WI doğrulamada kullanılabileceğini gösterir.	Deneysel kapsam ağırlıklı olarak Indic yazı sistemleriyle sınırlıdır.

Çalışma	Veri seti / protokol	Yöntem	Temel bulgu / katkı	Kapsam / sınırlılık
Huang ve Lu (2023) [9]	CEDAR, BHSig-Bengali, BHSig-Hindi, HanSig; WI	MS-SigNet + co-tuplet loss	Çok ölçekli temsil öğrenimiyle güçlü EER/AUC sonuçları üretir.	Perso-Arabik veri setleri üzerinde doğrudan değerlendirme içermez.
Brimoh ve Olisah (2024) [10]	GPDS-300, CEDAR, PUC-PR, MCYT; WD ağırlıklı	CNN temsilleri + consensus-threshold	Düşük FAR hedefleyen karar eşiği tasarımının doğrulama güvenliği açısından önemini vurgular.	WI genelleme sınırlı değerlendirilmiştir; düşük FAR bazı durumlarda FRR artışıyla dengelenebilir.
de Moura vd. (2024) [11]	GPDS Synthetic, CEDAR, MCYT; WI ve akış tabanlı	Stream-based doğrulama + adaptif sınıflandırıcı	İmza doğrulamada zamanla değişen veri dağılımı için uyarlanabilir değerlendirme çerçevesi sunar.	Statik benchmark karşılaştırmalarıyla doğrudan uyumu sınırlıdır; temsil modeli sentetik GPDS üzerinden eğitilmiştir.
Hafemann vd. (2019) [12]	MCYT-75, CEDAR, GPDS-160, Brazilian PUC-PR	Adversarial örnek analizi	Çevrimdışı imza doğrulamada adversarial dayanıklılığın ayrıca değerlendirilmesi gerektiğini gösterir.	Yazı sistemi, WD/WI protokolü ve omurga karşılaştırması çalışma odağında değildir.
Zhang vd. (2024) [13]	MCYT-75, GPDS-Synthetic	Feature-disentangling VAE + SVM	VAE tabanlı ayrıştırılmış temsillerin ayırt edici öznelik çıkarımına katkı sağlayabileceğini gösterir.	DeneySEL kapsam iki veri setiyle sınırlıdır; çoklu yazı sistemi karşılaştırması içermez.
Parracho (2025) [14]	CEDAR, ICDAR, GPDS Synthetic; çapraz-veri	Raw görüntü + shell preprocessing	Çapraz-veri seti genelleme için çevrimdışı imza doğrulamada hâlâ zor olduğunu gösterir.	Raw ve shell preprocessing yaklaşımları arasında tutarlı bir üstünlük ortaya koymaz.

Tablo 1’deki çalışmalar birlikte değerlendirildiğinde literatürün önemli bir bölümünün belirli bir mimari, belirli bir karar kuralı veya belirli bir veri seti üzerinde yoğunlaştığı görülmektedir. Derin temsil öğrenimi, Siamese ağlar, öz-gözetimli öğrenme ve eşikleme stratejileri güçlü katkılar sunmuş olsa da yazı sistemi farklılığı, WD/WI protokol ayrımı, omurga seçimi ve biyometrik hata ölçütleri çoğu zaman aynı kontrollü deneysel çerçevede birlikte ele alınmamaktadır. Bu çalışma, söz konusu boşluklara odaklanarak transfer öğrenme başarımının hangi koşullarda değiştiğini incelemektedir.

Çalışmanın temel araştırma sorusu şudur: transfer öğrenme tabanlı çevrimdışı imza doğrulamada başarımlar, veri seti/yazı sistemi, WD/WI değerlendirme protokolü, CNN omurgası ve ince ayar stratejisine ne ölçüde duyarlıdır? Bu soruya yanıt vermek için üç farklı yazı sistemini temsil eden veri setleri ve yaygın CNN omurgaları aynı deneysel çerçevede değerlendirilmiş; sonuçlar hem sınıflandırma doğruluğu hem de biyometrik hata ölçütleri açısından yorumlanmıştır.

Bu kapsamda çalışmanın katkıları aşağıda özetlenebilir:

1. Latin, Indic ve Perso-Arabik yazı sistemlerini temsil eden üç veri setinin ortak bir değerlendirme mantığıyla karşılaştırılması.
2. WD ve WI senaryolarının birlikte ele alınarak model başarımındaki genelleme farkının görünür kılınması.
3. Farklı temsil öğrenme varsayımlarına sahip dört yaygın CNN omurgasının karşılaştırmalı olarak incelenmesi.
4. Donmuş omurga yaklaşımı ile sınırlı son blok ince ayarı stratejisinin aynı problem bağlamında karşılaştırılması.
5. Doğruluk, kesinlik, duyarlılık, F1 ve ROC-AUC yanında FAR, FRR, AER ve EER gibi biyometrik ölçütlerin birlikte raporlanması.

2. Veri Setleri

Bu çalışmada üç farklı yazı sistemini temsil eden üç kamuya açık çevrimdışı imza veri seti kullanılmıştır. Veri setlerinin temel özellikleri Tablo 2’de özetlenmektedir.

Tablo 2. Çalışmada kullanılan çevrimdışı imza veri setlerinin temel özellikleri.

Özellik	CEDAR	BHSig260	UTSig
Yazı sistemi	Latin	Bengali + Devanagari	Perso-Arabik
Kişi sayısı	55	260	115
Gerçek imza	1.320	6.240	3.105
Sahte imza	1.320	7.800	4.830
Toplam kullanılan örnek	2.640	14.040	7.935
Sahtecilik türü	Yetenekli	Yetenekli	Yetenekli

2.1 CEDAR

CEDAR, Latin karakterli imzalardan oluşan ve çevrimdışı imza doğrulama literatüründe yaygın kullanılan klasik veri setlerinden biridir [16]. Bu çalışmada 55 kişiye ait 1.320 gerçek ve 1.320 yetenekli sahte imza kullanılmıştır. Veri setinin dengeli gerçek/sahte yapısı, sınıflandırma ve biyometrik metriklerin birlikte yorumlanması açısından uygun bir kıyaslama zemini sağlar.

2.2 BHSig260


BHSig260, 100 Bengali ve 160 Hindi/Devanagari olmak üzere toplam 260 yazara ait imzaları içeren büyük ölçekli bir Indic yazı sistemi veri setidir [17]. Her yazar için 24 gerçek ve 30 yetenekli sahte imza bulunur. Bu çalışmada Bengali ve Devanagari/Hindi alt kümeleri tek havuz olarak ele alınmış; toplam 6.240 gerçek ve 7.800 sahte imza değerlendirilmiştir.

2.3 UTSig

UTSig, Perso-Arabik imzalardan oluşan bir veri setidir ve özgün tanımında 115 yazar için gerçek imzalar, opposite-hand örnekleri ve yetenekli sahtecilikler içerir [18]. Bu çalışmada opposite-hand örnekleri değerlendirmeye alınmamış; yalnızca 3.105 gerçek ve 4.830 yetenekli sahte imza kullanılmıştır. Perso-Arabik yazının sağdan sola akışı, nokta kullanımı ve bağlantılı çizgi yapısı nedeniyle UTSig, yazı sistemi farklılığının etkisini incelemek için önemli bir senaryo sunmaktadır [18].

3. Yöntem

Bu bölümde veri setlerinin ortak ön işleme adımlarından başlayarak donmuş omurga transfer öğrenme kurulumu, karşılaştırılan CNN omurgaları, WD/WI değerlendirme protokolleri, VGG19 son blok ince ayar ablasyonu ve kullanılan metrikler açıklanmaktadır. Genel deneysel akış Şekil 1’de özetlenmiştir.



Şekil 1. Çoklu veri seti, WD/WI protokolü, donmuş omurga transfer öğrenme ve VGG19 son blok ince ayar ablasyonunu gösteren deneysel protokol.

3.1 Donmuş omurga transfer öğrenme

Ana deneylerde, ImageNet üzerinde önceden eğitilmiş CNN omurgalarının evrimsel katmanları dondurulmuş ve yalnızca sınıflandırıcı kafa eğitilmiştir. Bu yaklaşım, sınırlı sayıda imza örneğiyle kararlı eğitim yapılmasını sağlar ve omurgalar arasında adil bir karşılaştırma zemini oluşturur. Tüm omurgalarda sınıflandırıcı kafa aynı tutulmuştur: dropout (0,3), 256 nöronlu tam bağlı katman, ReLU aktivasyonu, ikinci dropout (0,3) ve iki sınıflı çıkış katmanı.

3.2 Karşılaştırılan CNN omurgaları

Çalışmada ResNet50, VGG19, DenseNet121 ve EfficientNet-B0 omurgaları aynı protokol altında değerlendirilmiştir. VGG19 küçük evrişim çekirdekleriyle düzenli ve derin bir yapı kurarken [19], ResNet50 artık bağlantılar sayesinde derin ağların optimize edilmesini kolaylaştırır [20]. DenseNet121, katmanlar arası yoğun bağlantılarla öznetelik yeniden kullanımını teşvik eder [21]. EfficientNet-B0 ise bileşik ölçekleme yaklaşımıyla model büyüklüğü ve doğruluk arasında verimli bir denge hedefler [22].

3.3 WD ve WI değerlendirme protokolleri

Her veri seti iki senaryoda değerlendirilmiştir. WD senaryosunda örnekler kişiye bakılmaksızın %80 eğitim ve %20 hold-out değerlendirme kümesine ayrılmıştır; dolayısıyla aynı yazarın farklı imzaları eğitim ve değerlendirme kümelerinde yer alabilir. WI senaryosunda ise bölme kişi bazında yapılmış olup bazı yazarların tüm imzaları eğitime, farklı yazarların tüm imzaları hold-out değerlendirmeye atanmıştır. Bu tasarımda değerlendirme yazarları eğitimde hiç görülmediği için WI protokolü daha gerçekçi ve daha zorlu bir genelleme testi sunar.

Erken durdurma, hold-out değerlendirme kümesi üzerindeki kayıp izlenerek uygulanmıştır. Bu kurulum, WI senaryosunda kişi ayrıklığını korur; ancak model seçimi ile nihai değerlendirme için tamamen ayrı kümeler kullanılmadığından çalışma sınırlılıkları arasında açıkça ele alınmıştır.

3.4 VGG19 son blok ince ayarı ablasyonu

Donmuş omurga kararının etkisini değerlendirmek için VGG19 üzerinde ek bir ablasyon yapılmıştır. Bu ablasyonda VGG19'un son evrişim bloğu çözülmüş ve sınıflandırıcı kafadan daha düşük bir öğrenme oranıyla ($lr=1e-5$) yeniden eğitilmiştir. Böylece önceden öğrenilmiş temsilin tamamen korunması ile sınırlı görev uyarlaması arasındaki fark altı senaryoda karşılaştırılmıştır.

3.5 Eğitim protokolü ve metrikler

Tüm deneylerde kullanılan hiperparametreler Tablo 3'te verilmiştir. Modeller doğruluk, kesinlik, duyarlılık, F1-skoru, ROC-AUC, yanlış kabul oranı (FAR), yanlış ret oranı (FRR), ortalama hata oranı (AER) ve eşit hata oranı (EER) ile değerlendirilmiştir. Doğruluk, kesinlik, duyarlılık ve F1-skoru sabit karar eşiğindeki sınıflandırma performansını özetlerken; ROC-AUC eşikten bağımsız ayırım gücünü, EER ise FAR ile FRR'nin dengelendiği karar noktasını temsil eder. Bu nedenle sonuçlar yalnızca doğruluk üzerinden değil, sınıflandırma ve biyometrik hata ölçütleri birlikte dikkate alınarak yorumlanmıştır.

Tablo 3. Deneylerde kullanılan ortak eğitim protokolü ve hiperparametreler.

Hiperparametre	Değer
Omurgalar	ResNet50, VGG19, DenseNet121, EfficientNet-B0 (ImageNet, donmuş)
İnce ayar	VGG19 son evrişim bloğu çözülür, $lr = 1e-5$
Optimizasyon	Adam, $lr = 1e-4$ (sınıflandırıcı kafa)
Ağırlık sönümü	$5e-4$
Batch boyutu	32
Epoch	30 (erken durdurma, sabır = 5)
Dropout	0,3
Görüntü boyutu	224×224 (ImageNet normalizasyonu)
Rastgelelik tohumu	42
Doğrulama/değerlendirme	%20 hold-out; erken durdurma ve nihai metrikler aynı kümede

4. DeneySEL Sonuçlar

Bu bölümde dört omurganın altı veri seti/senaryo kombinasyonundaki donmuş omurga sonuçları ve VGG19 son blok ince ayarı ablasyonu sunulmaktadır. Sonuçlar önce sınıflandırma metrikleri, ardından biyometrik hata ölçütleri ve son olarak ince ayar etkisi üzerinden değerlendirilmiştir.


4.1 Donmuş omurga sınıflandırma sonuçları

Tablo 4, dört omurganın altı senaryodaki doğruluk, kesinlik, duyarlılık, F1-skoru ve ROC-AUC değerlerini; Şekil 2 ise doğruluk karşılaştırmasını göstermektedir. VGG19, CEDAR-WD, BHSig-WD, BHSig-WI ve UTSig-WD senaryolarında en yüksek doğruluğu elde etmiş; böylece altı senaryonun dördünde öne çıkmıştır. Buna karşılık CEDAR-WI'da EfficientNet-B0, UTSig-WI'da ise DenseNet121 en yüksek doğruluğu vermiştir. UTSig-WI

senaryosunda VGG19'un F1-skorunun 0,434'e ve duyarlılığının 0,330'a gerilemesi, doğruluk düşüşünün gerçek imzaları reddetme eğilimiyle birlikte değerlendirilmesi gerektiğini göstermektedir.

Tablo 4. Donmuş omurga sınıflandırma sonuçları.

Veri / Senaryo	Omurga	Acc	Prec	Rec	F1	ROC-AUC
CEDAR-WD	ResNet50	0,945	0,914	0,981	0,946	0,991
CEDAR-WD	VGG19	0,977	0,963	0,992	0,977	0,996
CEDAR-WD	DenseNet121	0,962	0,958	0,966	0,962	0,996
CEDAR-WD	EfficientNet-B0	0,970	0,966	0,973	0,970	0,994
CEDAR-WI	ResNet50	0,866	0,832	0,917	0,872	0,938
CEDAR-WI	VGG19	0,915	0,954	0,871	0,911	0,976
CEDAR-WI	DenseNet121	0,879	0,817	0,977	0,890	0,985
CEDAR-WI	EfficientNet-B0	0,917	0,882	0,962	0,920	0,981
BHSig260-WD	ResNet50	0,772	0,770	0,675	0,719	0,831
BHSig260-WD	VGG19	0,958	0,961	0,943	0,952	0,992
BHSig260-WD	DenseNet121	0,799	0,785	0,739	0,761	0,872
BHSig260-WD	EfficientNet-B0	0,754	0,753	0,642	0,693	0,820
BHSig260-WI	ResNet50	0,808	0,812	0,740	0,775	0,880
BHSig260-WI	VGG19	0,823	0,804	0,794	0,799	0,885
BHSig260-WI	DenseNet121	0,818	0,798	0,791	0,795	0,892
BHSig260-WI	EfficientNet-B0	0,790	0,842	0,650	0,734	0,868
UTSig-WD	ResNet50	0,756	0,724	0,673	0,697	0,827
UTSig-WD	VGG19	0,906	0,927	0,842	0,882	0,961
UTSig-WD	DenseNet121	0,734	0,694	0,647	0,670	0,797
UTSig-WD	EfficientNet-B0	0,741	0,695	0,677	0,686	0,812
UTSig-WI	ResNet50	0,728	0,665	0,614	0,638	0,794
UTSig-WI	VGG19	0,663	0,633	0,330	0,434	0,690
UTSig-WI	DenseNet121	0,735	0,698	0,568	0,626	0,788
UTSig-WI	EfficientNet-B0	0,701	0,617	0,620	0,619	0,749



Şekil 2. Donmuş omurga doğruluk karşılaştırması. Değerler yüzde olarak gösterilmiştir.


Dikkat çekici sonuçlardan biri UTSig-WI senaryosunda ortaya çıkmaktadır. Bu senaryoda VGG19 doğruluğu %66,3'e düşmüş ve FRR %66,99 olarak gerçekleşmiştir. Bu değer, gerçek imzaların yaklaşık üçte ikisinin sahte olarak reddedildiğini ve buna karşılık duyarlılığın yaklaşık %33,01 düzeyinde kaldığını göstermektedir. Bu durum, yüksek kapasiteli bir omurganın kişi-bağımsız ve yazı sistemi bakımından farklı bir senaryoda her zaman daha iyi genelleme sağlamayabileceğine işaret etmektedir.

4.2 Donmuş omurga biyometrik sonuçları

Sınıflandırma metrikleri genel performansı gösterir; ancak imza doğrulama gibi güvenlik-kritik uygulamalarda biyometrik hata ölçütleri daha ayrıntılı bir görünüm sunar. Tablo 5 ve Şekil 3, donmuş omurgaların FAR, FRR, AER, EER ve ROC-AUC değerlerini birlikte vermektedir. Düşük FAR/FRR/AER/EER ve yüksek ROC-AUC daha iyi ayırım gücüne işaret eder.

Tablo 5. Donmuş omurga biyometrik sonuçları.

Veri / Senaryo	Omurga	FAR (%)	FRR (%)	AER (%)	EER (%)	ROC-AUC
CEDAR-WD	ResNet50	8,99	1,92	5,45	2,47	0,991
CEDAR-WD	VGG19	3,75	0,77	2,26	2,46	0,996
CEDAR-WD	DenseNet121	4,12	3,45	3,78	4,17	0,996
CEDAR-WD	EfficientNet-B0	3,37	2,68	3,03	2,46	0,994
CEDAR-WI	ResNet50	18,56	8,33	13,45	12,50	0,938
CEDAR-WI	VGG19	4,17	12,88	8,52	8,90	0,976
CEDAR-WI	DenseNet121	21,97	2,27	12,12	6,63	0,985
CEDAR-WI	EfficientNet-B0	12,88	3,79	8,33	7,95	0,981
BHSig260-WD	ResNet50	15,40	32,54	23,97	24,50	0,831
BHSig260-WD	VGG19	2,95	5,75	4,35	4,45	0,992
BHSig260-WD	DenseNet121	15,46	26,13	20,80	21,29	0,872
BHSig260-WD	EfficientNet-B0	16,09	35,83	25,96	25,22	0,820
BHSig260-WI	ResNet50	13,72	25,96	19,84	19,37	0,880
BHSig260-WI	VGG19	15,45	20,59	18,02	17,80	0,885
BHSig260-WI	DenseNet121	15,96	20,91	18,44	18,77	0,892
BHSig260-WI	EfficientNet-B0	9,74	35,02	22,38	22,04	0,868
UTSig-WD	ResNet50	18,40	32,73	25,56	26,48	0,827
UTSig-WD	VGG19	4,76	15,84	10,30	10,27	0,961
UTSig-WD	DenseNet121	20,45	35,29	27,87	28,17	0,797
UTSig-WD	EfficientNet-B0	21,32	32,28	26,80	26,97	0,812
UTSig-WI	ResNet50	19,88	38,65	29,26	28,35	0,794
UTSig-WI	VGG19	12,32	66,99	39,65	37,73	0,690
UTSig-WI	DenseNet121	15,84	43,16	29,50	30,30	0,788
UTSig-WI	EfficientNet-B0	24,74	38,00	31,37	31,15	0,749



Şekil 3. Donmuş omurga EER karşılaştırması. Düşük değer daha iyi performansı gösterir.

EER sonuçları, doğruluk tablosunda görülen örneği daha keskin hâle getirmektedir. VGG19, BHSig-WD senaryosunda EER'i %4,45'e, UTSig-WD senaryosunda %10,27'ye düşürerek WD koşullarında güçlü bir ayırım gücü sergilemiştir. Ancak UTSig-WI senaryosunda VGG19'un EER değeri %37,73'e yükselmiş ve ROC-AUC 0,690'a gerilemiştir. Bu sonuç, UTSig-WI koşulundaki sorunun yalnızca ham doğruluk düşüşü değil, biyometrik ayırım kapasitesindeki belirgin kayıp olduğunu göstermektedir.


4.3 VGG19 son blok ince ayarı ablasyonu

Tablo 6 ve Şekil 4, VGG19 donmuş omurga ile son blok ince ayarının altı senaryodaki sonuçlarını göstermektedir. İnce ayar, CEDAR-WD, BHSig-WD, BHSig-WI, UTSig-WD ve UTSig-WI senaryolarında EER değerini düşürmüştür. En belirgin iyileşmeler CEDAR-WD, BHSig-WD ve UTSig-WD senaryolarında görülmüştür. Bu durum, eğitimde görülen yazarların imza stillerine sınırlı uyarılamanın özellikle WD koşullarında yararlı olabileceğini düşündürmektedir.

Tablo 6. VGG19 ablasyonu: donmuş omurga ve son blok ince ayarı sonuçları.

Veri / Senaryo	Kurulum	Acc	FAR (%)	FRR (%)	AER (%)	EER (%)	ROC-AUC
CEDAR-WD	Donmuş	0,977	3,75	0,77	2,26	2,46	0,996
CEDAR-WD	Son blok	0,991	1,87	0,00	0,94	0,76	1,000
CEDAR-WI	Donmuş	0,915	4,17	12,88	8,52	8,90	0,976
CEDAR-WI	Son blok	0,901	8,33	11,36	9,85	8,90	0,967
BHSig260-WD	Donmuş	0,958	2,95	5,75	4,35	4,45	0,992
BHSig260-WD	Son blok	0,978	1,19	3,45	2,32	2,28	0,998
BHSig260-WI	Donmuş	0,823	15,45	20,59	18,02	17,80	0,885
BHSig260-WI	Son blok	0,842	15,58	16,19	15,88	15,95	0,901
UTSig-WD	Donmuş	0,906	4,76	15,84	10,30	10,27	0,961
UTSig-WD	Son blok	0,927	7,25	7,39	7,32	7,43	0,973
UTSig-WI	Donmuş	0,663	12,32	66,99	39,65	37,73	0,690
UTSig-WI	Son blok	0,687	13,25	59,42	36,34	35,10	0,718

Veri / Senaryo	Kurulum	Acc	FAR (%)	FRR (%)	AER (%)	EER (%)	ROC-AUC
----------------	---------	-----	---------	---------	---------	---------	---------



Şekil 4. VGG19 ablasyonu: donmuş omurga ve son blok ince ayarı. Düşük EER daha iyi performansı gösterir.

İnce ayarın koşulsal niteliği CEDAR-WI sonucunda açık biçimde görülmektedir. Bu senaryoda ince ayar doğruluğu 0,915'ten 0,901'e, ROC-AUC değerini 0,976'dan 0,967'ye düşürmüştü; EER değeri ise %8,90 ile değişmemiştir. Dolayısıyla ince ayar, özellikle küçük veri seti ve kişi-bağımsız değerlendirme koşullarında aşırı uyum veya temsil kayması riski taşıyabilir. UTSig-WI senaryosunda ince ayar EER'i %37,73'ten %35,10'a düşürse de model hâlâ yüksek hata rejiminde kalmıştır.

5. Tartışma

Bulgular, transfer öğrenme performansının yazı sistemi ile omurga seçimi arasındaki etkileşime duyarlı olduğunu göstermektedir. Latin karakterli CEDAR veri setinde tüm omurgalar görece yüksek başarımlar üretirken BHSig260 ve UTSig gibi Latin-dışı veri setlerinde omurgalar arası fark belirginleşmiştir. Bu durum, ImageNet üzerinde öğrenilen genel görsel temsillerin imza görüntülerine aktarılabilir olduğunu, ancak bu aktarımın yazı sisteminin yapısal özelliklerine bağlı olarak değiştiğini düşündürmektedir. VGG19'un WD senaryolarındaki başarısı, küçük evrişim çekirdekleri ve düzenli derin mimarisinin imza çizgilerindeki yerel örüntüleri yakalamada avantaj sağlayabileceği biçiminde yorumlanabilir. Ancak UTSig-WI sonucunda aynı omurga belirgin biçimde gerilemiştir. Bu sonuç, bir mimarinin belirli bir veri seti ve protokolde güçlü görünmesinin başka bir yazı sistemi ve kişi-bağımsız protokolde de aynı üstünlüğü koruyacağı anlamına gelmediğini ortaya koymaktadır.

WD ve WI sonuçları arasındaki fark, değerlendirme protokolünün performans yorumunda merkezi bir rol oynadığını göstermektedir. WD senaryosunda model, daha önce gördüğü yazarların imza dağılımına uyarlanabilir. Buna karşılık WI senaryosunda model, imza stili eğitimde hiç bulunmayan kişilere genelleme yapmak zorundadır. Bu nedenle WI performansı, sistemin gerçek uygulamalarda yeni kullanıcılara karşı nasıl davranabileceğine daha yakın bir gösterge sunar [2, 3, 6]. Bu çalışmada UTSig-WI senaryosu genelleme sınırlarını açık biçimde ortaya koymuştur. Perso-Arabik yazı sisteminin yapısal farklılığı, yazar havuzunun büyüklüğü ve sınıf dağılımı birlikte değerlendirildiğinde, modelin eğitimde öğrendiği temsiller yeni kişilere yeterince taşınmamış olabilir. Bu durum, çevrimdışı imza doğrulamada yalnızca yüksek ortalama doğruluk raporlamanın yeterli olmadığını; protokol ve veri seti koşullarının ayrıntılı biçimde belirtilmesi gerektiğini desteklemektedir.

Son blok ince ayarının çoğu senaryoda EER'i düşürmesi, önceden öğrenilmiş temsillerin hedef imza verisine sınırlı biçimde uyarlanmasının yararlı olabileceğini göstermektedir. Ancak CEDAR-WI örneği, ince ayarın her koşulda genelleme garantisi vermediğini açıkça ortaya koymuştur. Özellikle küçük veri setlerinde ve kişi-bağımsız

bölmelerde, son katmanların hedef veri üzerinde fazla özelleşmesi yeni yazarlar için ayırım gücünü azaltabilir. Bu sonuç, transfer öğrenme çalışmalarında “donmuş omurga mı, ince ayar mı?” sorusunun tek bir genel cevapla çözülemeyeceğini göstermektedir. Donmuş omurga, adil ve düşük varyanslı omurga karşılaştırması için uygun bir başlangıç noktasıdır. İnce ayar ise veri hacmi, yazı sistemi, protokol ve hedef metrik dikkate alınarak koşullu biçimde değerlendirilmelidir.

Doğruluk, sınıflandırma performansını özetlese de imza doğrulamada güvenlik ve kullanılabilirlik dengesini tek başına açıklamaz. FAR, sahte imzaların gerçek kabul edilmesiyle ilişkili güvenlik riskini; FRR ise gerçek kullanıcıların reddedilmesiyle ilişkili kullanılabilirlik kaybını gösterir. EER bu iki hata türünü tek bir karar noktasında özetlediği için biyometrik sistem karşılaştırmalarında daha açıklayıcıdır [1, 10]. Bu çalışmada UTSig-WI senaryosunda görülen yüksek FRR ve EER, doğruluk tablosunda görülen düşüşün pratikte ciddi bir kullanıcı reddi problemine karşılık geldiğini göstermektedir.

Bu çalışmanın bulguları, literatürde vurgulanan iki temel eğilimle uyumludur. Birincisi, derin temsiller çevrimdışı imza doğrulamada güçlü bir temel sunsa da genelleme başarısı veri seti ve protokole bağlıdır [2, 3]. İkincisi, transfer öğrenme ve özellik seçimi gibi stratejiler faydalı olabilir; ancak doğrulama stratejisi zayıf kurulduğunda aşırı uyum riski devam eder [5-7]. Çalışmanın özgün katkısı, bu eğilimleri üç yazı sistemi, iki protokol, dört omurga ve biyometrik metrikler üzerinden aynı protokolde birlikte göstermesidir. Ayrıca sonuçlar, imza doğrulama literatüründe giderek önem kazanan daha gerçekçi değerlendirme gereksinimiyle de örtüşmektedir. Çok ölçekli öznitelik öğrenimi, karar eşiği optimizasyonu, akış tabanlı güncellenebilir doğrulama, adversarial sağlamlık ve çapraz-veri genelleme gibi güncel araştırma hatları, imza doğrulamanın yalnızca statik doğruluk karşılaştırmasıyla sınırlı kalmaması gerektiğini göstermektedir [9-14]. Bu çalışma, söz konusu geniş yönelimin çoklu veri seti ve protokol duyarlılığı boyutuna katkı sunmaktadır.

6. Sınırlılıklar

Bu çalışmanın bazı sınırlılıkları vardır. İlk olarak deneyler sabit bir rastgelelik tohumu ve tek eğitim/değerlendirme bölmesiyle yürütülmüştür. Bu durum tekrarlanabilirliği artırsa da sonuçların istatistiksel varyansını değerlendirmek için yeterli değildir. Gelecek çalışmalarda çoklu tohum ve k-katlı yazar-bağımsız değerlendirme kullanılması sonuçların sağlamlığını artıracaktır. İkincisi, erken durdurma için kullanılan hold-out küme aynı zamanda nihai metriklerin hesaplandığı kümedir. Bu kurulum WI senaryosunda kişi ayrıklığını korumakla birlikte, model seçimi ve nihai test ölçümü tamamen bağımsız değildir. Üçüncüsü, UTSig-WI senaryosundaki genelleme kaybının aşırı uyumdan mı, temsil uyumsuzluğundan mı yoksa bölme yapısından mı kaynaklandığını kesin biçimde ayırmak için eğitim/değerlendirme kayıp eğrileri, çoklu bölmeler ve çapraz veri seti testleri gereklidir. Dördüncüsü, çalışmada yalnızca son blok ince ayarı incelenmiş; tam ince ayar, katman-katman çözme, veri artırma, alan uyarlaması veya modern transformer tabanlı görsel omurgalar bu çalışma kapsamına alınmamıştır. Bu nedenle bulgular, mevcut deneysel çerçeve ve kullanılan omurgalar bağlamında yorumlanmalıdır.

7. Sonuç

Bu çalışma, çevrimdışı imza doğrulamada transfer öğrenme başarımının yalnızca kullanılan CNN omurgasına değil; veri seti/yazı sistemi, WD/WI değerlendirme protokolü ve ince ayar stratejisine birlikte bağlı olduğunu göstermiştir. Donmuş omurga deneylerinde VGG19 çoğu senaryoda güçlü sonuçlar üretmiş, ancak UTSig-WI senaryosunda belirgin bir genelleme kaybı sergilemiştir. Bu bulgu, tek veri seti veya tek protokol üzerinden yapılan yüksek başarımların sınırlı kalabileceğini göstermektedir. VGG19 son blok ince ayarı çoğu senaryoda EER ve ROC-AUC bakımından iyileşme sağlamış; ancak CEDAR-WI örneğinde görüldüğü üzere ince ayar her koşulda daha iyi genelleme garantisi vermemiştir. Bu nedenle çevrimdışı imza doğrulama çalışmalarında yalnızca

doğruluk değerleri değil, kesinlik, duyarlılık, F1-skoru, FAR, FRR, AER ve EER gibi ölçütler de birlikte raporlanmalıdır. Gelecek çalışmalarda çoklu tohum, k-katlı yazar-bağımsız değerlendirme, bağımsız doğrulama/test ayrımı, çapraz veri seti testleri, alan uyarlaması, veri artırma ve transformer tabanlı görsel omurgaların aynı deneysel çerçevede incelenmesi önerilmektedir.

Kaynaklar

- [1] Hafemann, L. G., Sabourin, R., & Oliveira, L. S. (2015). Offline handwritten signature verification - Literature review. arXiv:1507.07909.
- [2] Hafemann, L. G., Sabourin, R., & Oliveira, L. S. (2017). Learning features for offline handwritten signature verification using deep convolutional neural networks. *Pattern Recognition*, 70, 163-176. <https://doi.org/10.1016/j.patcog.2017.05.012>
- [3] Dey, S., Dutta, A., Toledo, J. I., Ghosh, S. K., Lladós, J., & Pal, U. (2017). SigNet: Convolutional Siamese network for writer independent offline signature verification. arXiv:1707.02131.
- [4] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 248-255. <https://doi.org/10.1109/CVPR.2009.5206848>
- [5] Mersa, O., Etaati, F., Masoudnia, S., & Araabi, B. N. (2019). Learning representations from Persian handwriting for offline signature verification, a deep transfer learning approach. arXiv:1903.06249.
- [6] Souza, V. L. F., Oliveira, A. L. I., Cruz, R. M. O., & Sabourin, R. (2020). An investigation of feature selection and transfer learning for writer-independent offline handwritten signature verification. arXiv:2010.10025.
- [7] Ozyurt, F., Majidpour, J., Rashid, T. A., & Koc, C. (2024). Offline handwriting signature verification: A transfer learning and feature selection approach. arXiv:2401.09467.
- [8] Chattopadhyay, S., Manna, S., Bhattacharya, S., & Pal, U. (2022). SURDS: Self-supervised attention-guided reconstruction and dual triplet loss for writer independent offline signature verification. arXiv:2201.10138.
- [9] Huang, F.-H., & Lu, H.-M. (2023). Multiscale feature learning using co-tuplet loss for offline handwritten signature verification. arXiv:2308.00428.
- [10] Brimoh, P., & Olisah, C. C. (2024). Consensus-threshold criterion for offline signature verification using convolutional neural network learned representations. arXiv:2401.03085.
- [11] de Moura, K. G., Cruz, R. M. O., & Sabourin, R. (2024). Offline handwritten signature verification using a stream-based approach. arXiv:2411.06510.
- [12] Hafemann, L. G., Sabourin, R., & Oliveira, L. S. (2019). Characterizing and evaluating adversarial examples for offline handwritten signature verification. arXiv:1901.03398.
- [13] Zhang, H., Guo, J., Li, K., Zhang, Y., & Zhao, Y. (2024). Offline signature verification based on feature disentangling aided variational autoencoder. arXiv:2409.19754.
- [14] Parracho, M. R. (2025). Signature forgery detection: Improving cross-dataset generalization. arXiv:2510.17724.
- [15] de Moura, K. G., Sabourin, R., & Cruz, R. M. O. (2026). A prototypical signature approach for writer-independent offline signature verification. arXiv:2606.18528.
- [16] Kalera, M. K., Srihari, S., & Xu, A. (2004). Offline signature verification and identification using distance statistics. *International Journal of Pattern Recognition and Artificial Intelligence*, 18(7), 1339-1360.
- [17] Pal, S., Alaei, A., Pal, U., & Blumenstein, M. (2016). Performance of an off-line signature verification method based on texture features on a large Indic-script signature dataset. *12th IAPR Workshop on Document Analysis Systems (DAS)*, 72-77.
- [18] Soleimani, A., Fouladi, K., & Araabi, B. N. (2017). UTSig: A Persian offline signature dataset. *IET Biometrics*, 6(1), 1-8.
- [19] Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. *International Conference on Learning Representations (ICLR)*. arXiv:1409.1556.
- [20] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778.

- [21] Huang, G., Liu, Z., van der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 4700-4708.
- [22] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. Proceedings of the 36th International Conference on Machine Learning (ICML), PMLR 97, 6105-6114.