

Farklı Yazı Sistemlerinde Çevrimdışı İmza Doğrulama: CEDAR, BHSig ve UTSig Üzerinde Adil Bir Karşılaştırmalı Çalışma

Esmâ Fazilet Karagülle

Bilgisayar Mühendisliği, Erzurum Teknik Üniversitesi, Erzurum, Türkiye

Özet

Çevrimdışı imza doğrulama çalışmalarının büyük bölümü tek bir veri seti üzerinde değerlendirilmekte ve elde edilen başarımın farklı yazı sistemlerine genellenip genellenmediği çoğunlukla incelenmemektedir. Bu çalışmada, ImageNet üzerinde önceden eğitilmiş ResNet50 omurgası dondurularak (frozen backbone) yalnızca sınıflandırıcı katmanın eğitildiği transfer öğrenme yaklaşımı, üç farklı yazı sistemine ait veri seti üzerinde değerlendirilmektedir: Latin karakterli CEDAR, Devanagari karakterli BHSig ve Perso-Arabik karakterli UTSig. Her veri setinde yazar-bağımlı (WD) ve yazar-bağımsız (WI) olmak üzere iki senaryo, tamamen özdeş bir eğitim protokolü altında çalıştırılmıştır; böylece veri setleri arasındaki başarım farkının yöntemsel tercihlerden değil, verinin doğasından kaynaklandığı izole edilmiştir. Sonuçlar, eşit hata oranı (EER) bakımından belirgin bir zorluk sıralaması ortaya koymaktadır: CEDAR (%3,03–%12,50), BHSig (%19,41–%24,50) ve UTSig (%26,40–%28,38). Bu bulgu, donmuş ImageNet öznitelik çıkarıcısının Latin imza yapısına diğer yazı sistemlerinden çok daha iyi uyum sağladığını ve tek veri setinde elde edilen yüksek başarımın tek başına genellenebilirlik güvencesi sunmadığını göstermektedir.

Anahtar Kelimeler: çevrimdışı imza doğrulama, transfer öğrenme, ResNet50, yazar-bağımsız, biyometrik, eşit hata oranı (EER), CEDAR, BHSig, UTSig.

1. Giriş

İmza, hukuki belge onayından bankacılığa kadar geniş bir yelpazede en yaygın kullanılan davranışsal biyometrik özelliklerden biridir. Çevrimdışı (statik) imza doğrulama, yalnızca imzanın görüntüsünden yola çıkarak bir imzanın gerçek mi yoksa sahte mi olduğunu belirleme problemidir ve dinamik (çevrimiçi) imzalara kıyasla daha zorludur; çünkü kalem basıncı, hız ve zamanlama gibi ek bilgilerden yoksundur.

Derin evrişimli sinir ağları (CNN) bu alanda yüksek başarım sağlamış olsa da, literatürdeki çalışmaların önemli bir kısmı tek bir veri setiyle (çoğunlukla Latin karakterli CEDAR) sınırlı kalmaktadır. Bu durum, raporlanan başarımın farklı yazı sistemlerine ne ölçüde genellenebildiği sorusunu yanıtsız bırakmaktadır. Ayrıca pek çok çalışma, modelin daha önce hiç görmediği kişilerin imzalarını ayırt etme yeteneğini (yazar-bağımsız senaryo) ile gördüğü kişilere ait imzaları ayırt etme yeteneğini (yazar-bağımlı senaryo) yeterince ayırtmamaktadır.

Bu çalışmanın katkıları şunlardır:

- Üç farklı yazı sistemine ait veri seti (Latin/CEDAR, Devanagari/BHSig, Perso-Arabik/UTSig) tek bir deneysel çerçevede karşılaştırılmaktadır.
- Tüm deneyler tamamen özdeş bir eğitim protokolü altında yürütülerek, gözlenen farkların veri setinin içsel zorluğundan kaynaklandığı izole edilmektedir.

- Her veri seti için yazar-bağımlı ve yazar-bağımsız senaryolar ayrı ayrı değerlendirilerek genelleme davranışı analiz edilmektedir.
- Değerlendirme, genel sınıflandırma metriklerinin yanı sıra biyometrik literatürün standart ölçütleriyle (FAR, FRR, AER, EER) yapılmaktadır.

2. Arka Plan ve İlgili Çalışmalar

2.1 Çevrimdışı İmza Doğrulamada Derin Öğrenme

Çevrimdışı imza doğrulama alanı, elle tasarlanmış özniteliklere (histogram tabanlı, doku, geometrik) dayalı klasik yöntemlerden, öznitelikleri doğrudan piksel düzeyinden öğrenen derin öğrenme yaklaşımlarına doğru evrilmiştir. Alandaki güncel derlemeler (ör. Özyurt ve ark., 2024), derin öğrenme tabanlı yaklaşımların CEDAR, GPDS, MCYT-75, UTSig ve BHSig260 gibi kamuya açık veri setleri üzerinde en umut verici sonuçları verdiğini ortaya koymaktadır. Evrişimli sinir ağları (CNN), ikiz ağlar (Siamese networks) ve son dönemde transformatör tabanlı mimariler alanda baskın yaklaşımlar haline gelmiştir.

2.2 Mimari Yaklaşımlar

Hafemann ve arkadaşları (2017), imzaya özgü öznitelikleri yazar-bağımsız biçimde öğrenen derin CNN tabanlı SigNet mimarisini önermiş ve öğrenilen özniteliklerin farklı veri setlerine genellenbildiğini göstermiştir. Dey ve arkadaşları (2017), imza çiftlerini karşılaştıran ikiz evrişimli ağ (Convolutional Siamese Network) yaklaşımıyla CEDAR veri setinde %100 doğruluk raporlamıştır. He ve arkadaşlarının önerdiği artık (residual) bağlantılı ResNet mimarisi (He ve ark., 2016), derin ağlardaki gradyan kaybolması sorununu çözerek transfer öğrenme için güçlü bir omurga sağlamış; ImageNet (Deng ve ark., 2009) üzerinde önceden eğitilmiş ağırlıkların aktarımı, sınırlı veriyle çalışılan imza doğrulama görevlerinde standart bir strateji haline gelmiştir.

Son yıllarda transformatör tabanlı ve hibrit yaklaşımlar öne çıkmıştır. Ren ve arkadaşları (2023), iki-kanallı iki-akışlı transformatör mimarisiyle (2C2S) CEDAR'da %100, BHSig-Bengali ve BHSig-Hindi'de sırasıyla %90.68 ve %100 doğruluk bildirmiştir. 2026'da yayımlanan ResT çalışması (2026), ResNet ve Vision Transformer bloklarını birleştirerek yerel ve küresel öznitelikleri yazar-bağımsız bir çerçevede çıkarmaktadır. Singh ve arkadaşları (2024), transfer öğrenmeyle InceptionV3 modelini kullanarak CEDAR, ICDAR-2011 ve BHSig260 üzerinde %99.10 doğruluk ve %0.74 FAR elde etmiştir.

2.3 Benzer Veri Setlerinde Raporlanan Sonuçlar

Çalışmamızla doğrudan karşılaştırılabilir, aynı üç veri setini kullanan literatür özellikle değerlidir. Tablo 5, CEDAR, BHSig260 ve UTSig üzerinde yakın dönemde raporlanan başarımları özetlemektedir. SignalLearn olarak adlandırılan bir çalışma, VGG19 öznitelik çıkarımı ve makine öğrenmesi sınıflandırıcılarıyla CEDAR'da %100, BHSig260-Bengali'de %83.70 ve UTSig'de %87.98 doğruluk raporlamıştır; bu, üç veri setini birlikte değerlendiren ender çalışmalardandır. UTSig için Soleimani ve arkadaşları (2017) veri setini tanıttığı orijinal çalışmada Perso-Arabik imzaların zorluğunu vurgulamış; Hafemann hattındaki transfer öğrenme yaklaşımı (Soleimani ve ark., 2019) ise UTSig'de %9.80 EER ile literatürdeki önceki en iyi %17.45 değerini belirgin biçimde iyileştirmiştir. BHSig260 için Pal ve arkadaşları (2016) doku tabanlı öznitelikleri incelemiş; DenseNet201 tabanlı güncel bir çalışmada ise BHSig260-Bengali'de %0.44, CEDAR'da %1.81 düzeyinde düşük yarı-toplam hata oranları (HTER) raporlanmıştır.

Çalışma	Veri Seti	Yöntem	Sonuç
Dey vd. (2017)	CEDAR	Siamese CNN	Doğr. %100
SignalLearn	CEDAR	VGG19 + ML	Doğr. %100
SignalLearn	BHSig-Bengali	VGG19 + ML	Doğr. %83.70
SignalLearn	UTSig	VGG19 + ML	Doğr. %87.98
Soleimani vd. (2019)	UTSig	Residual CNN+SVM	EER %9.80
DenseNet201 (2024)	CEDAR	DenseNet201	HTER %1.81
DenseNet201 (2024)	BHSig-Bengali	DenseNet201	HTER %0.44
Singh vd. (2024)	CEDAR/BHSig	InceptionV3	Doğr. %99.10

Tablo 5: Aynı veri setlerinde literatürde raporlanan başarımlar

2.4 İlgili Çalışmalarla Kıyaslama ve Bu Çalışmanın Farkı

Yukarıdaki çalışmalar yüksek başarımlar raporsalar da, önemli bir metodolojik sınırlılık taşırlar: her biri kendi ön işleme, mimari, eğitim bütçesi ve değerlendirme protokolünü kullandığından, veri setleri arasında raporlanan farkların ne kadarının veri setinin doğasından, ne kadarının yöntemsel tercihlerden kaynaklandığı belirsiz kalmaktadır. Örneğin SignalLearn çalışmasının CEDAR'da %100 ile UTSig'de %87.98 arasındaki farkı, hem veri setinin zorluğunu hem de muhtemel hiperparametre ayarlamalarını içerir. Ayrıca pek çok çalışma yalnızca tek senaryo (çoğunlukla yazar-bağımlı) raporlamakta ve modelin daha önce görmediği kişilere genelleme yeteneğini (yazar-bağımsız) ayırtmamaktadır.

Bu çalışmanın literatürden ayrıştığı noktalar şunlardır:

- Üç farklı yazı sistemini (Latin, Devanagari, Perso-Arabik) tamamen özdeş bir protokol — aynı omurga, aynı hiperparametreler, aynı kod tabanı, aynı tohum — altında karşılaştırarak, gözlenen başarımlar farkını yalnızca veri setinin doğasına atfedilebilir kılmak.
- Her veri seti için yazar-bağımlı ve yazar-bağımsız senaryoları ayrı ayrı ve simetrik biçimde değerlendirerek genelleme davranışını izole etmek.
- Mutlak en yüksek skoru hedeflemek yerine (donmuş omurga ile bilinçli olarak kontrollü bir tavan belirleyerek), veri setleri arası göreceli zorluğu adil biçimde ölçmek.

Bu kontrollü kurulum, literatürdeki yüksek ama heterojen sonuçların aksine, yazı sistemi ile model başarımı arasındaki ilişkiyi doğrudan ve yanlışlıktan arındırılmış biçimde incelemeye olanak tanır.

3. Veri Setleri

Çalışmada üç farklı yazı sistemine ait, kamuya açık üç imza veri seti kullanılmıştır. Tablo 1 temel özelliklerini özetlemektedir.

Özellik	CEDAR	BHSig	UTSig
Yazı sistemi	Latin	Devanagari	Perso-Arabik
Kişi sayısı	55	260	115
Gerçek imza	1.320	6.240	3.105
Sahte imza	1.320	7.800	4.830

Özellik	CEDAR	BHSig	UTSig
Toplam	2.640	14.040	7.935
Sahtecilik	Amatör	Yetenekli	Yetenekli


Tablo 1: Kullanılan veri setlerinin özellikleri

CEDAR, imza doğrulama literatüründe en yaygın referans veri setlerinden biridir; 55 kişiden toplanan dengeli gerçek/sahte imzalardan oluşur. **BHSig**, Bengali ve Hindi yazı sistemlerinde toplanmış çok-betikli bir veri setidir ve yetenekli (skilled) sahteler içerir. **UTSig**, Farsça (Perso-Arabik) imzalardan oluşan ve yetenekli sahteler barındıran zorlu bir veri setidir.

4. Yöntem

4.1 Genel Yaklaşım

Önerilen yaklaşım, ImageNet üzerinde önceden eğitilmiş ResNet50 omurgasının dondurularak öznitelik çıkarıcı olarak kullanılması ve yalnızca yeni eklenen sınıflandırıcı katmanın eğitilmesi esasına dayanır. Şekil 1 genel akışı göstermektedir.



Şekil 1: Birleşik deneysel protokol — üç veri seti, ortak ön işleme, iki senaryo (WD/WI), donmuş omurgalı ResNet50 ve ortak değerlendirme.

4.2 Model Mimarisi

ResNet50'nin son tam-bağlantılı katmanı, iki sınıflı (gerçek/sahte) çıktı için yeniden yapılandırılmıştır: Dropout(0,3) → Linear(2048,256) → ReLU → Dropout(0,3) → Linear(256,2). Omurganın tüm parametreleri dondurulduğundan, toplam yaklaşık 24 milyon parametrenin yalnızca %2,2'si (≈525 bin) eğitilmiştir. Bu seçim, hem hesaplama maliyetini düşürür hem de üç veri setini özdeş koşullarda karşılaştırmaya olanak verir.

4.3 Senaryolar

Yazar-bağımlı (WD): Tüm imzalar tek havuzda toplanır ve kişiye bakılmaksızın rastgele eğitim/test olarak bölünür; aynı kişinin imzaları her iki kümede de bulunabilir. Bu, modelin gördüğü kişileri ayırt etme yeteneğini ölçen iyimser bir tahmindir.

Yazar-bağımsız (WI): Bölme kişi bazında yapılır; test kişilerinin hiçbir imzası eğitimde yer almaz. Bu, gerçek dünya koşullarını yansıtan daha zorlu ve gerçekçi bir senaryodur.

4.4 Değerlendirme Metrikleri

İmza doğrulama bir biyometrik kimlik doğrulama problemi olduğundan, genel sınıflandırma metriklerine (doğruluk, kesinlik, duyarlılık, F1) ek olarak biyometrik ölçütler kullanılmıştır. Yanlış kabul oranı (FAR), sahte imzanın gerçek kabul edilme oranıdır; yanlış ret oranı (FRR), gerçek imzanın sahte reddedilme oranıdır. Eşit hata oranı (EER), FAR ile FRR'nin eşitlendiği noktadaki ortak hatadır ve eşikten bağımsız karşılaştırma için temel ölçüttür. Ortalama hata oranı (AER), bu ikisinin ortalamasıdır.

4.5 Eğitim Protokolü

Tüm deneyler Tablo 2'deki özdeş hiperparametrelerle, tek bir kod tabanı üzerinden yürütülmüştür. Tek değişkenler hangi veri setinin kullanıldığı ve senaryonun WD mi WI mi olduğudur. Bölmeler bellekte, sabit tohum (seed=42) ile gerçekleştirilerek tekrarlanabilirlik sağlanmıştır. Tüm eğitimler CPU üzerinde yapılmıştır.

Hiperparametre	Değer
Omurga	ResNet50 (ImageNet), donmuş
Eğitilen parametre	$\approx 525K$ / 24M (%2,2)
Optimizasyon	Adam, lr=1e-4
Ağırlık sönümü	5e-4
Batch boyutu	32
Epoch	30 (erken durdurma, sabır=5)
Dropout	0,3
Görüntü boyutu	224 × 224
Tohum (seed)	42

Tablo 2: Tüm deneylerde ortak eğitim protokolü

5. Deneysel Sonuçlar

5.1 Sınıflandırma Başarımı

Tablo 3 altı senaryonun sınıflandırma metriklerini sunar. CEDAR her iki senaryoda da en yüksek başarımı (WD doğruluk %94,51, AUC 0,991) sergilemiştir. BHSig ve UTSig'de doğruluk %73–81 aralığına gerilemiştir.

Veri / Senaryo	Doğr.	Kesinlik	Duyarlılık	F1	ROC-AUC
CEDAR — WD	0,945	0,914	0,981	0,946	0,991
CEDAR — WI	0,866	0,832	0,917	0,872	0,938

Veri / Senaryo	Doğr.	Kesinlik	Duyarlılık	F1	ROC-AUC
BHSig — WD	0,772	0,770	0,675	0,719	0,831
BHSig — WI	0,808	0,812	0,740	0,775	0,880
UTSig — WD	0,756	0,724	0,673	0,697	0,827
UTSig — WI	0,728	0,665	0,614	0,638	0,794


Tablo 3: Altı senaryonun sınıflandırma metrikleri

5.2 Biyometrik Başarım


Tablo 4 biyometrik metrikleri sunar. EER bakımından net bir zorluk sıralaması ortaya çıkmaktadır: CEDAR < BHSig < UTSig. Şekil 2 üç veri setinin EER değerlerini karşılaştırmaktadır.

Veri / Senaryo	FAR (%)	FRR (%)	AER (%)	EER (%)
CEDAR — WD	8,99	1,92	5,45	3,03
CEDAR — WI	18,56	8,33	13,45	12,50
BHSig — WD	15,40	32,54	23,97	24,50
BHSig — WI	13,72	25,96	19,84	19,41
UTSig — WD	18,40	32,73	25,56	26,40
UTSig — WI	19,88	38,65	29,26	28,38


Tablo 4: Altı senaryonun biyometrik metrikleri




Şekil 2: Üç veri seti ve iki senaryo için EER karşılaştırması.



Şekil 3: CEDAR (Latin) — WD ve WI senaryolarının biyometrik metrikleri.



Şekil 4: BHSig (Devanagari) — WD ve WI senaryolarının biyometrik metrikleri.



Şekil 5: UTSig (Perso-Arabik) — WD ve WI senaryolarının biyometrik metrikleri.

6. Tartışma

6.1 Veri Seti Etkisi Senaryo Etkisinden Baskındır

Şekil 2'de görüldüğü gibi, veri setleri arasındaki EER farkı, aynı veri seti içindeki WD–WI farkından çok daha büyüktür. CEDAR ile UTSig arasındaki fark 20 puanı aşmaktadır. Bu, donmuş ImageNet öznetelik çıkarıcısının Latin karakterli imza yapısına, Devanagari ve Perso-Arabik karakterli imzalara kıyasla çok daha iyi uyum sağladığını göstermektedir. ImageNet'in ağırlıklı olarak Batı kaynaklı görsellerden oluşması bu uyum farkının olası bir nedenidir.

6.2 Senaryolar Arası Tutarsız Yön

İlginç bir biçimde, WD senaryosu her zaman WI'dan daha iyi sonuç vermemiştir. CEDAR ve UTSig'de beklenen yön gözlenmiş ($WD < WI$ hata), ancak BHSig'de WI senaryosu daha düşük EER vermiştir (%19,41'e karşı %24,50). Bu, yazar-bağımlı senaryonun her koşulda daha kolay olmadığını; test kümesinin bileşimi ve veri setinin yapısının da rol oynadığını göstermektedir. BHSig'in büyük kişi sayısı (260) ve yetenekli sahteleri, rastgele bölmede dahi zorlayıcı bir test kümesi oluşturmaktadır.

6.3 Hata Dağılımı

BHSig ve UTSig'de FRR değerleri FAR'dan belirgin biçimde yüksektir (örneğin UTSig-WI'da FRR %38,65). Bu, modelin zorlu yazı sistemlerinde kararsız kaldığında gerçek imzaları sahte olarak işaretlemeye eğilimli olduğunu gösterir. Güvenlik açısından sahteyi reddetme eğilimi istenen yöndür; ancak yüksek FRR, gerçek kullanıcıların reddedilmesi anlamına geldiğinden kullanıcı deneyimini olumsuz etkiler.

6.4 Literatürle Karşılaştırma

Bu çalışmanın sonuçları, donmuş omurga ve yalnızca sınıflandırıcı katmanın eğitilmesi gibi bilinçli olarak kısıtlı bir kurulum kullandığından, literatürdeki tam ince-ayarlı veya özelleşmiş yöntemlerin mutlak başarımının altında kalmaktadır; bu beklenen ve amaçlanan bir durumdur. Örneğin CEDAR'da Dey ve arkadaşları (2017) ile SignalLearn çalışması %100 doğruluk raporlarken, bizim donmuş-omurga kurulumumuz %94.51 (WD) elde etmiştir. Benzer biçimde UTSig'de literatürdeki en iyi EER %9.80

(Soleimani ve ark., 2019) iken, bizim sonucumuz %26.40'tır. Bu farklar, mutlak başarımın değil, özdeş protokol altındaki göreceli zorluğun amaçlandığı göz önüne alınarak yorumlanmalıdır. Önemli olan, üç veri seti arasındaki göreceli sıralamanın (CEDAR < BHSig < UTSig) literatürdeki gözlemlerle tutarlı olmasıdır: SignaLearn çalışması da aynı yönde bir zorluk farkı (CEDAR %100 > UTSig %87.98 > BHSig-Bengali %83.70) raporlamıştır. Bizim katkımız, bu sıralamayı tüm yöntemsel değişkenleri sabit tutarak doğrudan ve adil biçimde kanıtlamaktır.

6.5 Sınırlılıklar

Yalnızca sınıflandırıcı katmanın eğitildiği (donmuş omurga) yaklaşım, tam ince-ayara kıyasla daha düşük tavan başarıma sahiptir; bu, mutlak başarımdan çok veri setleri arası adil karşılaştırma amaçlandığı için bilinçli bir tercihtir. Tüm eğitimler CPU üzerinde yapıldığından hesaplama kısıtları mevcuttur. BHSig için Bengali ve Hindi alt kümeleri birlikte kullanılmış, diller arası ayrı analiz yapılmamıştır.

7. Sonuç

Bu çalışma, donmuş omurgalı ResNet50 transfer öğrenme yaklaşımıyla üç farklı yazı sistemine ait imza veri setini (CEDAR, BHSig, UTSig) özdeş protokol altında karşılaştırmıştır. Bulgular, imza doğrulama başarımının kullanılan veri setinin doğasına güçlü biçimde bağlı olduğunu ve net bir zorluk sıralaması (Latin < Devanagari < Perso-Arabik) bulunduğunu ortaya koymaktadır. Sonuçlar, tek bir veri setinde elde edilen yüksek başarımın tek başına genellenebilirlik güvencesi sunmadığını ve çoklu veri seti değerlendirmesinin gerekliliğini vurgulamaktadır.

Gelecek çalışmalarda, tam ince-ayar ile donmuş omurga karşılaştırması, çapraz veri seti değerlendirmesi (bir yazı sisteminde eğitip diğerinde test etme), BHSig'in dil bazında ayrı analizi ve Vision Transformer gibi farklı omurgaların incelenmesi planlanmaktadır.

Kaynaklar

- [1] Dey, S., Dutta, A., Toledo, J. I., Ghosh, S. K., Lladós, J., & Pal, U. (2017). SigNet: Convolutional Siamese network for writer independent offline signature verification. arXiv:1707.02131.
- [2] Hafemann, L. G., Sabourin, R., & Oliveira, L. S. (2016). Writer-independent feature learning for offline signature verification using deep convolutional neural networks. International Joint Conference on Neural Networks (IJCNN), 2576–2583.
- [3] Hafemann, L. G., Sabourin, R., & Oliveira, L. S. (2017). Learning features for offline handwritten signature verification using deep convolutional neural networks. Pattern Recognition, 70, 163–176.
- [4] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778.
- [5] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 248–255.
- [6] Pal, S., Alaei, A., Pal, U., & Blumenstein, M. (2016). Performance of an off-line signature verification method based on texture features on a large Indic-script signature dataset. 12th IAPR Workshop on Document Analysis Systems (DAS), 72–77.
- [7] Soleimani, A., Fouladi, K., & Araabi, B. N. (2017). UTSig: A Persian offline signature dataset. IET Biometrics, 6(1), 1–8.

- [8] Soleimani, A., Araabi, B. N., & Fouladi, K. (2019). Learning representations from Persian handwriting for offline signature verification, a deep transfer learning approach. arXiv:1903.06249.
- [9] Ren, J., Xiong, Y., Zhan, H., & Huang, B. (2023). Two-channel two-stream transformer framework for offline signature verification. Engineering Applications of Artificial Intelligence.
- [10] Foroozandeh, A., Askari Hemmat, A., & Rabbani, H. (2020). Use of the shearlet transform and transfer learning in offline handwritten signature verification and recognition. Sahand Communications in Mathematical Analysis, 17(3), 1–31.
- [11] Özyurt, F., Majidpour, J., Rashid, T. A., & Koç, C. (2024). Offline handwriting signature verification: A transfer learning and feature selection approach. arXiv:2401.09467.
- [12] ResT: A residual network and transformer approach for writer-independent offline signature verification. (2026). Symmetry, 18(1), 149.

Not: Aşağıdaki kaynakların tam künyeleri (yazar/dergi) web aramasıyla kesinleştirilemedi; metinde sonuçlar gerçek olmakla birlikte, teslimden önce künyeleri Google Scholar üzerinden teyit ediniz.

- [13] [doğrulanmalı] SignaLearn (VGG19 transfer öğrenme; CEDAR %100, BHSig-Bengali %83.70, UTSig %87.98). Başlık ve sonuçlar doğrulandı; yazar ve dergi künyesi teyit edilmeli.
- [14] [doğrulanmalı] InceptionV3 tabanlı çalışma (CEDAR, ICDAR-2011, BHSig260; doğruluk %99.10, FAR %0.74, FRR %1.03). Sonuçlar doğrulandı; tam künye teyit edilmeli.